刘威

AI Agent 开发 / FDE · 意向城市：北京

电话 / 微信：18210811086 · 邮箱：18210811086@163.com

知乎后端 8 年。2024 年起参与直答的 RAG 与专业搜索智能体，做过检索链路、生成评估和多智能体编排；此前主导搜索从 Lucene 迁到 Elasticsearch。能把检索方案、智能体分工和线上稳定性讲清楚，并有高并发业务系统的交付记录。

工作经历

知乎｜后端开发工程师｜2018.11 – 至今

直答 RAG 与专业搜索｜参与｜2024 年初 – 至今

面向千万日活的 AI 搜索。在成本、时效、准确性和可解释性的约束下，采用 RAG，而不是对基座做持续预训练。

- 参与把 Query 理解从单轮检索改为多轮上下文；参与专用改写模型的微调，并接到搜索引擎。召回同时使用语义、标签和向量空间对齐，融合 BGE 长文与短文模型，在控制成本的前提下提升相关性与多样性。
- 参与 Chunk 选型：比较固定窗口、生成式和归并式后，落地归并式（相关度排序、片段合并、边界扩展），缓解长上下文中段被忽略的问题，同时控制延迟和成本。Rerank 综合相关性、多样性与社区权威度。
- 参与自动评估（偏好模型、bad case 集）、人工盲评（GSB）和 AB 实验，并用 DAG 编排做全链路监控，作为上线前的效果闸门。
- 参与专业搜索的多智能体：按信息查询、内容分析、数学计算拆分，配合文档解析（含 PDF）和动态调度，支撑 5000 万篇以上中英文文献及维普等论文库的检索与深度阅读；参与接入 DeepSeek-R1 等外部模型，覆盖 Web / App。

推理服务 ZhiLight｜参与｜2024 年初 – 至今

参与自研推理框架 ZhiLight 的多卡调度与通信优化，并与 vLLM、SGLang 做性能对比和选型。参与知海图（知乎与面壁智能联合）的训练与推理工程，用 JuiceFS 保障 checkpoint。服务覆盖 70B 以上及 LLaMA-like 模型，部署在多种英伟达设备上，对外提供 OpenAI 兼容接口。

搜索引擎重构｜2018.11 – 2023.12

支撑 2 亿以上用户、千万日活的站内搜索。负责搜索引擎、个性化推荐和数据同步。

- 主导搜索从 Lucene 迁到 Elasticsearch：设计分片路由和索引生命周期，支撑 1.6 亿篇以上文章的实时检索。查询响应从约 300ms 降到 50ms 以内，峰值 QPS 到 5 万以上。
- 设计并实现 itag 用户画像，用浏览、点赞、收藏行为做兴趣标签，以协同过滤做个性化搜索推荐。搜索页 CTR 提升约 20%，优质用户次周留存提升约 11%。
- 重构 MySQL 与 Elasticsearch 的同步：Canal 解析 binlog，经 Kafka 做分布式事务消息，保证数据一致，同步延迟从分钟级降到秒级。
- 优化内容更新链路，用队列聚簇写入、批量提交和连接池复用应对突发发文。发文量约 5 倍时，延迟恶化从约 60% 控制在 15% 以内。

技能

- **Agent / RAG**：多轮 Query 理解与改写、混合召回、Chunk、Rerank、任务拆分、文档解析、自动评估与 AB 实验
- **工程**：Go（Gin / gRPC）、Python（FastAPI）、MySQL、Redis、Kafka、Elasticsearch、Canal
- **推理**：vLLM / SGLang 选型对比、多卡调度、OpenAI 兼容接口

教育

山东师范大学｜通信工程｜本科｜2012 – 2016